

UNIVERSIDAD EAFI  
ST0263 TOPICOS ESPECIALES EN TELEMÁTICA  
2026-1

## Proyecto 2 de BIG DATA

### I. Integrantes del proyecto:

- Emanuel Gonzalez Quintero, [egonzalezq@eafit.edu.co](mailto:egonzalezq@eafit.edu.co)
- Tomas Londoño Lopera [tlondonol1@eafit.com](mailto:tlondonol1@eafit.com)
- Samuel Madrid Ossa [smadrid@eafit.edu.co](mailto:smadrid@eafit.edu.co)

Repositorio github del proyecto3: <https://github.com/HardlinePizza21/Big-Data-Project>

Cada grupo de trabajo cargará este documento y lo compartirá con el profesor en cualquiera las 2 nubes:

- OneDrive de Office365 con la cuenta de EAFIT, se compartirá a: [aeospinas@eafit.edu.co](mailto:aeospinas@eafit.edu.co)

Deberán enviar un correo inicial por Eafit Interactiva, especificando los integrantes y en cual nube.

### II. Requerimientos

1. Crear un caso de estudio donde procese datos almacenados en fuentes de datos Bases de Datos, Archivo y URL. Deberá conseguir un conjunto de datos, típicamente archivos en datasets públicos, los cuales pueda almacenar una parte en bases de datos como Además en este caso de estudio, deberá plantear diferentes preguntas / hipótesis negocio que contestará con estos datos (ej: si son datos climáticos, que ciudad fue la caliente en abril de 2025 en Colombia, u ordene los departamentos de Colombia por temperatura promedio durante un periodo de tiempo). Esto se irá refinando conforme desarrollando el proyecto:

Pregunta 1: ¿Qué estación tiene el índice de calor promedio (apparent\_temperature) más alto?

Pregunta 2: ¿Generalmente hace más calor durante la primera mitad o la segunda mitad del mes?

Pregunta 3: ¿Qué estaciones registran la mayor precipitación acumulada anual y cómo varía a través de los años?

Pregunta 4: ¿Cómo varía la humedad relativa promedio a lo largo del año y cuál es su relación con la temperatura aparente?

Pregunta 5: ¿Qué municipios presentan las concentraciones promedio más altas de PM2.5 y PM10, los contaminantes más peligrosos para la salud respiratoria?

2. Fuentes de datos: Deberá simular datos en RDS MariaDB, archivos en una instancia de EC2 y URLs en Internet
3. Ingestar datos hacia el Datalake (AWS S3) en las zonas correctas. Deberá ser un proceso automático.

4. Realizar procesamiento orientado a la Preparación de datos (desde zona raw a trusted), herramientas a utilizar: AWS Glue y Apache Spark.
5. Realizar catalogación de tablas SQL con herramientas como AWS Glue y EMR/Hive
6. Realizar consultas procesamiento analítico descriptivo con SQL utilizando AWS Athena, EMR/Hive y SparkSQL.
7. Realizar consultas y procesamiento analítico descriptivo con Spark en Python (pyspark).
8. Realizar alguna aplicación de visualización de datos (con herramientas como matplotlib, dash, powerBI, grafana, etc) y alguna aplicación expuesta mediante API Gateway con Streamlit de Python.

En este documento, deberá adjuntar todas las evidencias de cada uno de puntos, a través descripciones, pantallazos y extractos de código importante.

También, deberá crear un repositorio github, crear un directorio explicito por cada uno de estos 8 puntos, adjuntando evidencias, código fuente y lo más importante: todas las instrucciones y archivos para que el profesor u otra persona pueda reproducir todo el proyecto

### III. Desarrollo:

